

# Mutation d'un virus

# **Abstract**

Ce document présente les méthodes de détection des *malwares*. Il montre également les faiblesses des technologies utilisées en s'orientant sur des codes polymorphiques.

La dernière version de ce document est accessible sur le Web à l'adresse :

http://esl.epitech.net/~arnaud/mutation-d'un-virus

Pour toutes questions et commentaires concernant ce document, merci de contacter: maillard.arnaud@gmail.com

## Table des matières

Introduction	
Détection d'un virus	
Détection par signature	
Un exemple de signature: les fichiers EICAR	
Détection par heuristiques	
Heuristiques sur le format	
Heuristiques sur le corps du programme	
Détection par émulation	
Mutation d'un virus	6
Chiffrement et déchiffrement	-
Manipuler les opcodes	-
Polymorphisme	10
Ídée générale	10
Concepts	1
La génération de nombres	
La génération de code	
Conclusion & ressources	17
Ressources	17

# Introduction

Depuis l'apparition des premiers virus, le marché des produits de sécurité s'est considérablement développé. Pour les créateurs de codes malicieux - autant que pour ceux essayant de les circonvenir - il a fallu -inventer de nouvelles méthodes d'infection et de détection.

Les premiers codes auto-reproducteurs étaient bien des prouesses, mais des prouesses où les architectures matérielles et logicielles ne restreignaient aucun accès, que ce soit sur les fichiers, la mémoire, ou même l'écran ou le disque dur. De plus, rien ne venait contrôler leur prolifération au sein d'une machine, et le concept d'anti-malwares n'existait pour ainsi dire pas.

Aujourd'hui, cette situation a considérablement changé. Processeurs et systèmes d'exploitations restreignent les accès, le parc d'utilisateur s'est étoffé, et les codes malicieux doivent tenir une course permanente avec les outils visant à leur élimination.

On s'intéresse dans ce document aux termes de cette course, présentant d'abord comment on peut affirmer de la présence d'un virus sur une machine, puis comment s'évader de ces mécanismes.

# Détection d'un virus

Il existe nombres de méthodes pour détecter les virus - ou au moins avertir l'utilisateur d'un fichier suspect - mais toutes peuvent se classer dans au moins l'une de ces trois familles:

- détection par signature
- détection par heuristiques
- détection par émulation

# Détection par signature

Une signature est une suite d'octets caractéristiques, une séquence identifiable servant à identifier la présence d'un code malicieux à l'intérieur d'un exécutable. Il s'agit d'un *pattern* dégageant des propriétés, celui-ci pouvant être construit autour d'un modèle plus ou moins complexe, pouvant tirer profit des expressions réqulières.

Un antivirus par signature procède donc à une analyse minutieuse, comparant deux suites d'octets. La première constitue le fichier soumis à vérification, la seconde déclarée comme constituante d'un code malicieux. Ce type de logiciel est spécifique, n'étant capable de reconnaître une menace que si elle est connue et présente dans ses bases de donnée.

# Un exemple de signature: les fichiers EICAR

Le code EICAR est un code compris dans les bases de l'ensemble des produits de sécurité du marché. Chaque fois que l'un d'eux le rencontre, il le signale par convention comme un virus, même si ce code ne présente aucune menace.

Historiquement, cette signature a été intégrée pour que les utilisateurs puissent vérifier que le logiciel qu'il venait d'acquérir fonctionnait correctement, qu'il réagissait à la présence de menaces présentes sur la machine. Divers organismes indépendants ont essayé de faire la même chose, sans succès toutefois.

Le code EICAR se présente comme suit :

X50!P%@AP[4\PZX54(P^)7CC)7}\$EICAR-STANDARD-ANTIVIRUS-TEST-FILE!\$H+H\*

En copiant ce texte dans un éditeur de texte puis modifiant l'extension du fichier, on obtient un fichier executable au format COM.

```
C:\ViNDOWS\system32\cmd.exe

C:\>eicar.com
EICAR-STANDARD-ANTIVIRUS-TEST-FILE!
C:\>
```

```
$ hexdump eicar.com

00000000 58 35 4f 21 50 25 40 41 50 5b 34 5c 50 5a 58 35 
0000010 34 28 50 5e 29 37 43 43 29 37 7d 24 45 49 43 41 
0000020 52 2d 53 54 41 4e 44 41 52 44 2d 41 4e 54 49 56 
0000030 49 52 55 53 2d 54 45 53 54 2d 46 49 4c 45 21 24 
0000040 48 2b 48 2a 
0000044
```

# Détection par heuristiques

Une heuristique peut être considéré comme un schéma, un fait vérifiable concernant:

- la structure d'un fichier exécutable
- le code contenue à l'intérieur de ce fichier

La détection par heuristique se base sur l'idée que la plupart des codes malicieux présentent des caractéristiques communes et génériques, isolables comme le sont les signatures, mais n'en possédant pas la rigidité.

## Heuristiques sur le format

La plupart des virus vont effectuer des opérations mettant à jour différents champs dans la structure PE (*Portable Executable*) du fichier infecté. Chaque heuristique va alors pouvoir inspecter ces modifications et les rapporter à l'utilisateur.

point d'entrée sur la dernière section

Il est très inhabituel que le champ EntryPoint du PE pointe ailleurs que sur la première section.

point d'entrée avant la première section

Ce cas est plus rare que le premier mais est utilisé quelquefois, constituant un comportement suspicieux manifeste.

#### SizeOfCode

Le champ *SizeOfCode* comptabilise les octets contenus dans les sections marqués *execute*. La plupart des virus ne le mettent pas à jour, le loader Windows ne le vérifiant pas.

caractéristiques des sections

En général, les compilateurs et assembleurs forment la première section comme étant la seule exécutable. Il est donc suspect de trouver la dernière section du fichier comme présentant la même caractéristique.

Dans le même ordre d'idée, il est suspect de trouver une section marquée des en même temps des drapeaux execute et writable.

nom et caractéristiques des sections

On rapporte ici le nom d'une section avec les caractéristiques qui lui ont été attribué. Il est par exemple illogique que la section des ressources, usuellement nommée « .rsrc », possède le drapeau execute.

## Heuristiques sur le corps du programme

lci, les heuristiques vont s'intéresser au code exécutable d'une application, y recherchant des comportements caractéristiques, ou au moins suspicieux.

redirection du flux d'exécution

Les virus ne modifiant pas l'EntryPoint du fichier infecté peuvent substituer aux premières instructions originales une opération de modification du flux (JMP / CALL).

Il est suspect que les instructions d'une section exécutable appellent des instructions d'une autre section exécutable.

Il est également suspect de trouver une séquence d'instruction de type PUSH / RET.

recherche et ouverture de fichiers PE

Pour infecter d'autres programmes, le virus va devoir utiliser les APIs Windows de recherche et d'ouverture de fichier (FindFirstFile, FindNextFile, CreateFile, etc.).

chaînes de caractères

En plus de l'utilisation d'API, le virus peut embarquer des chaînes de caractères suspectes, par exemple « \*.exe » ou les signatures DOS et PE des fichiers trouvés par le couple FindFirstFile / FindNextFile.

appel d'APIs via une adresse mémoire

Certains virus appellent les APIs Windows en utilisant une adresse mémoire, comportement très improbable pour un programme sain.

récupération de limageBase de KERNEL32

Pour utiliser les APIs Windows, un virus - s'il n'adresse pas directement l'espace de KERNEL32.DLL - doit retrouver où se situe la DLL en mémoire.

delta offset

La technique du delta offset est utilisée dans nombre de virus pour obtenir un code « position independent ».

# Détection par émulation

Une méthode simple pour contrecarrer les méthodes mises en oeuvre par les précédentes techniques de détection est le chiffrement du corps du virus, ajoutant à l'infection un mécanisme de chiffrement et d'exécution du code, cette-fois sous une forme compréhensible par le processeur.

Un produit de sécurité analysant un programme chiffré pourra bien tester les heuristiques sur la structure PE, mais seront faussées:

- la recherche de signature
- les heuristiques sur le corps du programme

Le flux analysé n'étant pas le code réellement exécuté, le produit a de grandes chances de signaler un fichier sain alors qu'il est infecté.

Le principe de l'émulation est de laisser s'exécuter le programme dans un environnement cloisonné puis de commencer l'analyse à partir d'un certain point, faisant entrer en jeu les principes évoqués précédemment.

# Mutation d'un virus

Le chiffrement du virus sert à contrer son identification. Le but ici est d'empêcher une méthode générique de désassemblage, donc l'identification d'une signature.

Dans les exemples suivants, correspondant à une possible première génération d'un virus, la section de code n'a pas la propriété *write*. On utilisera donc le programme ci-dessous.

```
/**
 ** pewrite.c
 ** changes the write attribute of the code section in a PE file
 **
 **/
#include <windows.h>
#include <stdio.h>
int
        main(int argc, char **argv)
{
  PIMAGE_SECTION_HEADER pImageSectionHeader;
  PIMAGE DOS HEADER
                        pImageDosHeader;
  PIMAGE_NT_HEADERS
                         pImageNtHeaders;
  PIMAGE_FILE_HEADER
                        pImageFileHeader;
  HANDLE
                        hFile;
  HANDLE
                        hFileMappingObject;
  LPVOID
                        lpFileMappedView;
                        dwCount;
  DWORD
  if (argc < 2)
    return (-1);
  hfile = CreateFile(argv[1], GENERIC READ | GENERIC WRITE, FILE SHARE READ,
                     NULL, OPEN_EXISTING, FILE_ATTRIBUTE_NORMAL, NULL);
  if (hFile == INVALID HANDLE VALUE)
    return (-1);
  hFileMappingObject = CreateFileMapping(hFile, NULL, PAGE_READWRITE, 0, 0,
                                          NULL);
  if (hFileMappingObject == NULL)
    return (-1);
  lpFileMappedView = MapViewOfFile(hFileMappingObject, FILE_MAP_ALL_ACCESS,
0,
                                    0, 0);
  if (lpFileMappedView == NULL)
    return (-1);
```

```
pImageDosHeader = (PIMAGE_DOS_HEADER) lpFileMappedView;
 if (pImageDosHeader->e_magic != IMAGE DOS SIGNATURE)
   return (-1);
 pImageNtHeaders = (PIMAGE_NT_HEADERS) ((DWORD) lpFileMappedView +
                                         pImageDosHeader->e lfanew);
 if (pImageNtHeaders->Signature != IMAGE NT SIGNATURE)
   return (-1);
 pImageSectionHeader = (PIMAGE SECTION HEADER) ((DWORD) pImageNtHeaders +
                                                 sizeof (IMAGE NT HEADERS));
 for (dwCount = 0;
      dwCount != pImageNtHeaders->FileHeader.NumberOfSections;
      dwCount++) {
   if (pImageNtHeaders->OptionalHeader.BaseOfCode ==
        pImageSectionHeader->VirtualAddress)
     pImageSectionHeader->Characteristics |= IMAGE SCN MEM WRITE;
   pImageSectionHeader = (PIMAGE SECTION HEADER)
      ((DWORD) pImageSectionHeader + sizeof (IMAGE SECTION HEADER));
 }
 return (0);
}
```

## Chiffrement et déchiffrement

Les programmes suivants illustre le chiffrement d'un programme. On applique simplement une opération de type XOR.

# Manipuler les opcodes

```
; m1.asm

.586
.model flat, stdcall option casemap :none
.code

start:

mov eax,1
mov ebx,2
mov ecx,3
mov edx,4
ret
```

```
0:000> u $exentry
image00400000+0x1000:
00401000 b801000000
                                  eax,1
                          mov
00401005 bb02000000
                                  ebx,2
                          mov
0040100a b903000000
                                  ecx,3
                          mov
0040100f ba04000000
                                  edx,4
                          mov
00401014 c3
                          ret
; m2.asm
; code XOR 0x06
.586
.model flat, stdcall
option casemap :none
.code
start:
              esi,code_begin
       mov
              edi,code_begin
       mov
              ecx,code_end - code_begin
       mov
1:
       lodsb
       xor
              eax,06h
       stosb
       loop
              1
       jmp
              code end
code_begin:
       mov
              eax,1
              ebx,2
       mov
              ecx,3
       mov
       mov
              edx,4
code end:
       ret
end
       start
0:000> u $exentry
image00400000+0x1000:
                                  esi,offset image00400000+0x1018 (00401018)
00401000 be18104000
                          mov
00401005 bf18104000
                                  edi,offset image00400000+0x1018 (00401018)
                          mov
0040100a b914000000
                                  ecx,14h
                          mov
                                  byte ptr [esi]
0040100f ac
                          lods
00401010 83f006
                          xor
                                  eax,6
00401013 aa
                                  byte ptr es:[edi]
                          stos
                                  image00400000+0x100f (0040100f)
00401014 e2f9
                          loop
00401016 eb14
                                  image00400000+0x102c (0040102c)
                          jmp
00401018 b801000000
                                  eax,1
                          mov
0040101d bb02000000
                          mov
                                  ebx,2
```

end

start

```
00401022 b903000000
                          mov
                                  ecx,3
00401027 ba04000000
                          mov
                                  edx,4
0040102c c3
                          ret
0:000> g
0:000> u $exentry
image00400000+0x1000:
00401000 be18104000
                                  esi, offset image00400000+0x1018 (00401018)
                          mov
00401005 bf18104000
                                  edi,offset image00400000+0x1018 (00401018)
                          mov
0040100a b914000000
                          mov
                                  ecx,14h
0040100f ac
                                  byte ptr [esi]
                          lods
00401010 83f006
                                  eax,6
                          xor
                                  byte ptr es:[edi]
00401013 aa
                          stos
00401014 e2f9
                          loop
                                  image00400000+0x100f(0040100f)
00401016 eb14
                          jmp
                                  image00400000+0x102c (0040102c)
00401018 be07060606
                                  esi,6060607h
                          mov
0040101d bd04060606
                                  ebp,6060604h
                          mov
00401022 bf05060606
                                  edi,6060605h
                          mov
00401027 bc02060606
                                  esp,6060602h
                          mov
0040102c c3
                          ret
; m3.asm
; (code XOR 0x06) XOR 0x06
.model flat, stdcall
option casemap :none
.code
start:
              esi,code_begin
       mov
              edi, code begin
       mov
       mov
              ecx,code_end - code_begin
1:
       lodsb
              eax,06h
       xor
       stosb
       loop
code begin:
       db
              0beh
       dd
              06060607h
       db
              0bdh
              06060604h
       dd
       db
              0bfh
       dd
              06060605h
       db
              0bch
              06060602h
       dd
code end:
       ret
```

```
end
      start
0:000> u $exentry
image00400000+0x1000:
00401000 be16104000
                                  esi, offset image00400000+0x1016 (00401016)
                         mov
00401005 bf16104000
                                  edi, offset image00400000+0x1016 (00401016)
                         mov
                                  ecx,14h
0040100a b914000000
                         mov
0040100f ac
                         lods
                                  byte ptr [esi]
00401010 83f006
                                  eax,6
                         xor
00401013 aa
                         stos
                                  byte ptr es:[edi]
00401014 e2f9
                                  image00400000+0x100f(0040100f)
                         loop
00401016 be07060606
                                  esi,6060607h
                         mov
0040101b bd04060606
                                  ebp,6060604h
                         mov
00401020 bf05060606
                         mov
                                  edi,6060605h
00401025 bc02060606
                                  esp,6060602h
                         mov
0040102a c3
                         ret
0:000> bp 0040102a
0:000> g
0:000> r eax,ebx,ecx,edx
eax=00000001 ebx=00000002 ecx=00000003 edx=00000004
```

# **Polymorphisme**

Le but du polymorphisme est de brouiller l'ensemble des signatures potentielles, extractibles à partir d'un virus. La naissance de cette technique est étroitement liée à la situation initiale des programmes antivirus, soit des bases de signatures. Le polymorphisme tend à éliminer toutes les parties fixes du corps d'un virus.

En effet, même avec une technique de chiffrement, quelques octets restent fixes. Le décrypteur ne change pas. Alors plutôt que de s'attaquer au corps du virus proprement dit, les chercheurs des laboratoires antivirus ont simplement identifié les décrypteurs. La signature passait ici de constituante d'un code malicieux à ... constituante du mécanisme de déchiffrement du code.

Le polymorphisme signifie donc la génération de multiples décrypteurs. Le principe est simple : ne jamais produire de décrypteurs identiques, avec pour contrainte de garder un schéma opératif intact.

#### Idée générale

Puisque le polymorphisme est essentiellement une génération de décrypteurs, il faut bien penser le fonctionnement interne de celui-ci. Usuellement on aura un code similaire à celui-ci:

```
mov ecx,(taille du code à chiffrer/déchiffrer)
lea edi,(pointeur vers le code à chiffrer/déchiffrer)
mov eax,(clé de chiffrement/déchiffrement)

Boucle:
xor dword ptr [edi],eax
add edi,4
loop Boucle
```

Ce code est facilement marquable. On peut aisément en extraire une signature. Quels sont les éléments qui s'offrent à nous pour rendre ce code moins identifiable ? On peut :

- modifier les registres utilisés
- modifier l'ordre des instructions

- utiliser des instructions « équivalentes »
- insérer des instructions ne servant à rien (junk code)

Un moteur de polymorphisme va donc se décomposer essentiellement en deux parties:

- Un générateur de nombres pseudo aléatoires
- Un i générateur de décrypteur

# Concepts

# La génération de nombres

Le générateur de nombres pseudo aléatoires (GNPA) est utile puisqu'il va nous permettre d'opérer des changements sur le code produit.

Par exemple, si on veut utiliser un registre au hasard, ou produire une valeur immédiate aléatoire (*imm32*), ou encore générer des *opcodes*.

Un générateur pauvre en entropie pourrait se baser sur l'API GetSystemTime.

```
; m4.asm
; using GetSystemTime
.586
.model flat, stdcall
option casemap :none
  include \masm32\include\windows.inc
  include \masm32\include\user32.inc
  include \masm32\include\kernel32.inc
  includelib \masm32\lib\user32.lib
  includelib \masm32\lib\kernel32.lib
.data
 _SYSTEMTIME
Year dw
Month
                    STRUC
                    dw
                            ?
  DayOfWeek dw
        dw
dw
  Day
  Hour
 Minute
                    dw
                           ?
                    dw
                           ?
  Second
 Milliseconds dw _SYSTEMTIME ENDS
                    ENDS
             _SYSTEMTIME <>
  STime
.code
start:
  call random
  push 0
  call ExitProcess
random proc
```

```
push offset STime
  call GetSystemTime
  xor eax,eax
  mov ax,[STime.Milliseconds]
  ret
  random endp
end start
```

A la sortie de ce programme, le registre AX contient un nombre généré aléatoirement.

La structure SYSTEMTIME ne comportant que des WORD, il serait judicieux d'améliorer la sortie de la fonction de génération en utilisant des DWORD (en décalant les bits par exemple).

Il est très important de se concentrer sur cette partie du système polymorphique, puisque plus le générateur est bon, plus il va nous permettre d'encoder des opérations diverses, et donc d'améliorer la génération du code.

# La génération de code

D'abord, améliorons le GNPA en lui fournissant une fonction par laquelle on peut spécifier une valeur maximale.

```
; m5.asm
; using GetSystemTime with RNDMAX
.586
.model flat, stdcall
option casemap :none
      include \masm32\include\windows.inc
      include \masm32\include\user32.inc
      include \masm32\include\kernel32.inc
      includelib \masm32\lib\user32.lib
      includelib \masm32\lib\kernel32.lib
.data
       SYSTEMTIME STRUC
      Year
                   dw
                   dw
                          ?
      Month
      DayOfWeek
                   dw
                          ?
      Day
                   dw
      Hour
                   dw
                          ?
      Minute
                   dw
      Second
                   dw
      Milliseconds dw
      SYSTEMTIME ENDS
      STime SYSTEMTIME <>
      RNDMAX equ
.code
start:
             eax, RNDMAX
      mov
      call rand
```

```
push
              0
       call
              ExitProcess
rand
       proc
       push
              ecx
              edx
       push
       mov
              ecx,eax
       call
              random
       xor
              edx,edx
       div
              ecx
              eax,edx
       mov
       pop
              edx
       pop
              ecx
       ret
rand
       endp
random proc
       pusha
              offset STime
       push
              GetSystemTime
       call
       popa
       xor
              eax,eax
              ax,[STime.Milliseconds]
       mov
       ret
random endp
end
       start
```

Dans cet exemple, la valeur retournée dans EAX ne dépassera pas RNDMAX. Ceci est très utile si on veut codifier les registres.

```
_EAX equ 0
_ECX equ 1
_EDX equ 2
_EBX equ 3
```

De cette manière, nous pouvons désormais gérer les instructions qui font intervenir un registre (MOV REG,IMM32 par exemple).

```
; m6.asm
; generates MOV reg32, imm32
.586
.model flat, stdcall
option casemap :none
    include \masm32\include\windows.inc
    include \masm32\include\user32.inc
    include \masm32\include\kernel32.inc
    includelib \masm32\lib\user32.lib
```

# includelib \masm32\lib\kernel32.lib

#### .data

```
_SYSTEMTIME STRUC
      Year
                  dw
                        ?
      Month
                  dw
                        ?
      DayOfWeek dw ?
      Day
                  dw
      Hour
                  dw ?
      Minute
                  dw ?
      Second
                  dw ?
      Milliseconds dw
      _SYSTEMTIME ENDS
      STime SYSTEMTIME <>
      RNDMAX equ
      EAX
      ECX
            equ
                  1
      EDX
            equ
      _EBX
                  3
            equ
.code
start:
      jmp
            realstart
codebuffer:
      db
                       ; mov reg32
            0
      dd
            0
                        ; imm32
      db
                        ; ret
realstart:
            edi,offset codebuffer
      mov
            eax, RNDMAX
      mov
      call
            rand
            al,0B8h
      or
      stosb
      call
            random
      stosd
            al,0c3h
                          ; ret opcode
      mov
      stosb
            offset _end
      push
      jmp
            codebuffer
_end:
            0
      push
      call
           ExitProcess
rand proc
```

```
push
             ecx
      push
             edx
      mov
             ecx,eax
       call
             random
             edx,edx
      xor
       div
             ecx
      mov
             eax,edx
             edx
      pop
             ecx
      pop
      ret
rand
      endp
random proc
       pusha
      push
             offset STime
       call
             GetSystemTime
       popa
       xor
             eax,eax
             ax,[STime.Milliseconds]
      mov
       shl
             eax,16
             ax,[STime.Second]
      mov
       ret
random endp
      start
end
0:000> u $exentry
image00400000+0x1000:
00401000 eb06
                          jmp
                                  image00400000+0x1008 (00401008)
                                  byte ptr [eax],al
00401002 0000
                          add
00401004 0000
                          add
                                  byte ptr [eax],al
00401006 0000
                          add
                                  byte ptr [eax],al
00401008 bf02104000
                                  edi,offset image00400000+0x1002 (00401002)
                          mov
0040100d b804000000
                          mov
                                  eax,4
                                  image00400000+0x1031 (00401031)
00401012 e81a000000
                          call
00401017 0cb8
                                  al,0B8h
                          or
. . .
0:000> bp 00401028
0:000> g
image00400000+0x1028:
00401028 ebd8
                          jmp
                                  image00400000+0x1002 (00401002)
0:000> u 00401002
image00400000+0x1002:
00401002 ba2a001400
                          mov
                                  edx,14002Ah
00401007 c3
                          ret
0:000> .reload
0:000> g
image00400000+0x1028:
00401028 ebd8
                                  image00400000+0x1002 (00401002)
                          jmp
```

0:000> u 00401002 image00400000+0x1002:

00401002 bb0b008302 mov ebx,283000Bh

00401007 c3 ret

Le même principe peut être appliqué aux instructions du décrypteur.

# **Conclusion & ressources**

La génération de codes polymorphiques est une bonne manière de s'initier à la manière dont sont conduits les flux d'instruction. Ils permettent également de se rapprocher du traitement effectué par le processeur en termes d'opcodes.

## Ressources

# Intel 64 and IA-32 Architectures Software Developer's Manuals:

Volume 2A: Instruction Set Reference, A-M

http://www.intel.com/Assets/PDF/manual/253666.pdf

Volume 2B: Instruction Set Reference, N-Z

http://www.intel.com/Assets/PDF/manual/253667.pdf

# The Molecular Virology of Lexotan32: Metamorphism Illustrated

https://www.openrce.org/articles/full\_view/29

# The Viral Darwinism of W32.Evol

https://www.openrce.org/articles/full\_view/27

## MASM32 (Microsoft assembler)

http://www.masm32.com

## OllyDbg

http://www.ollydbg.de

# Debugging tools for Windows

http://www.microsoft.com/whdc/DevTools/Debugging/default.mspx